ΕΘΝΙΚΟ ΜΕΤΣΟΒΙΟ ΠΟΛΥΤΕΧΝΕΙΟ
ΣΧΟΛΗ ΗΛΕΚΤΡΟΛΟΓΩΝ ΜΗΧΑΝΙΚΩΝ ΚΑΙ ΜΗΧΑΝΙΚΩΝ ΥΠΟΛΟΓΙΣΤΩΝ
ΤΟΜΕΑΣ ΤΕΧΝΟΛΟΓΙΑΣ ΠΛΗΡΟΦΟΡΙΚΗΣ ΚΑΙ ΥΠΟΛΟΓΙΣΤΩΝ

ΠΡΟΧΩΡΗΜΕΝΑ ΘΕΜΑΤΑ ΒΑΣΕΩΝ ΔΕΔΟΜΕΝΩΝ
ΕΞΑΜΗΝΙΑ ΕΡΓΑΣΙΑ 2022-2023

ΟΜΑΔΑ 40

Ονοματεπώνυμο	**Αριθμός Μητρώου**
Νικόλαος Μπλέτσας	03118899
Γεώργιος Τζουμανέκας	03118095

Github link

https://github.com/GeoTzoum/atds-team40

Εισαγωγή files στο hdfs

Αρχικά εγκαταστήσαμε με τα κατάλληλα configurations το Spark και το HDFS. Για να ξεκινήσουμε την λειτουργία του HDFS εκτελούμε την εντολή *start-dfs.sh* και για την να ξεκινήσουμε την λειτουργία του Spark εκτελούμε την εντολή *start-all.sh.* Δημιουργούμε το directory με την εντολή *hadoop fs -mkdir hdfs://master:9000/files/* στο οποίο φορτώνουμε το ένα αρχέιο με την εντολή *hadoop fs -put hdfs://master:9000/files/taxi+_zone_lookup.csv*. Έπειτα φτιάχνουμε ένα νέο directory files/taxi στο hadoop που θα εισάγουμε όλα τα parquet αρχεία με τον ίδιο τρόπο.

Αποτελέσματα από την εκτέλεση των queries

Q1 sql:

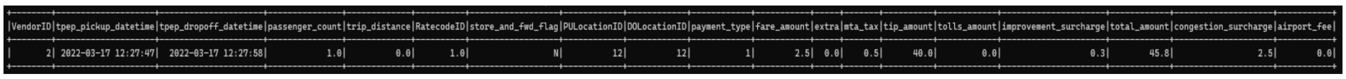

```
+--------+--------------------+---------------------+---------------+-------------+----------+------------------+------------+------------+------------+-----------+-----+-------+----------+------------+---------------------+------------+--------------------+-----------+
|VendorID|tpep_pickup_datetime|tpep_dropoff_datetime|passenger_count|trip_distance|RatecodeID|store_and_fwd_flag|PULocationID|DOLocationID|payment_type|fare_amount|extra|mta_tax|tip_amount|tolls_amount|improvement_surcharge|total_amount|congestion_surcharge|airport_fee|
+--------+--------------------+---------------------+---------------+-------------+----------+------------------+------------+------------+------------+-----------+-----+-------+----------+------------+---------------------+------------+--------------------+-----------+
|       2| 2022-03-17 12:27:47|  2022-03-17 12:27:58|            1.0|          0.0|       1.0|                 N|          12|          12|           1|        2.5|  0.0|    0.5|      40.0|         0.0|                  0.3|        45.8|                 2.5|        0.0|
+--------+--------------------+---------------------+---------------+-------------+----------+------------------+------------+------------+------------+-----------+-----+-------+----------+------------+---------------------+------------+--------------------+-----------+
```

Q2 sql:

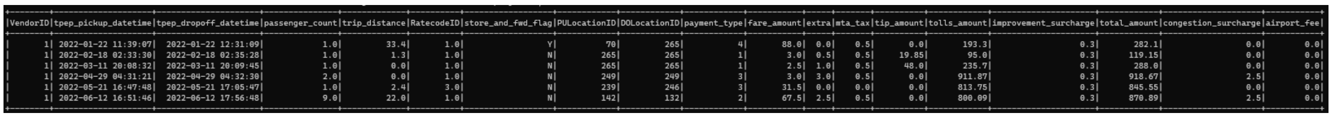

```
+--------+--------------------+---------------------+---------------+-------------+----------+------------------+------------+------------+------------+-----------+-----+-------+----------+------------+---------------------+------------+--------------------+-----------+
|VendorID|tpep_pickup_datetime|tpep_dropoff_datetime|passenger_count|trip_distance|RatecodeID|store_and_fwd_flag|PULocationID|DOLocationID|payment_type|fare_amount|extra|mta_tax|tip_amount|tolls_amount|improvement_surcharge|total_amount|congestion_surcharge|airport_fee|
+--------+--------------------+---------------------+---------------+-------------+----------+------------------+------------+------------+------------+-----------+-----+-------+----------+------------+---------------------+------------+--------------------+-----------+
|       1| 2022-01-22 11:39:07|  2022-01-22 12:31:09|            1.0|         33.4|       1.0|                 Y|          70|         265|           4|       88.0|  0.0|    0.5|       0.0|       193.3|                  0.3|       282.1|                 0.0|        0.0|
|       1| 2022-02-18 02:33:30|  2022-02-18 02:35:28|            1.0|          1.3|       1.0|                 N|         265|         265|           1|        3.0|  0.5|    0.5|     19.85|        95.0|                  0.3|      119.15|                 0.0|        0.0|
|       1| 2022-03-11 20:08:32|  2022-03-11 20:09:45|            1.0|          0.0|       1.0|                 N|         265|         265|           1|        2.5|  1.0|    0.5|      48.0|       235.7|                  0.3|       288.0|                 0.0|        0.0|
|       1| 2022-04-29 04:31:21|  2022-04-29 04:32:30|            2.0|          0.0|       1.0|                 N|         249|         249|           3|        3.0|  3.0|    0.5|       0.0|      911.87|                  0.3|      918.67|                 2.5|        0.0|
|       1| 2022-05-21 16:47:48|  2022-05-21 17:05:47|            1.0|          2.4|       3.0|                 N|         239|         246|           3|       31.5|  0.0|    0.0|       0.0|      813.75|                  0.3|      845.55|                 0.0|        0.0|
|       1| 2022-06-12 16:51:46|  2022-06-12 17:56:48|            9.0|         22.0|       1.0|                 N|         142|         132|           2|       67.5|  2.5|    0.5|       0.0|      800.09|                  0.3|      870.89|                 2.5|        0.0|
+--------+--------------------+---------------------+---------------+-------------+----------+------------------+------------+------------+------------+-----------+-----+-------+----------+------------+---------------------+------------+--------------------+-----------+
```

Q3 sql:

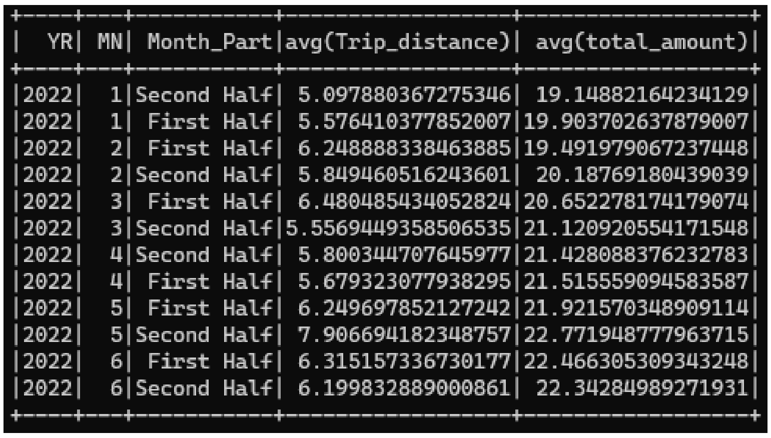

```
+----+---+-----------+-----------------+------------------+
|  YR| MN| Month_Part|avg(Trip_distance)| avg(total_amount)|
+----+---+-----------+-----------------+------------------+
|2022|  1|Second Half| 5.097880367275346| 19.14882164234129|
|2022|  1| First Half| 5.576410377852007|19.903702637879007|
|2022|  2| First Half| 6.248888338463885|19.491979067237448|
|2022|  2|Second Half| 5.849460516243601| 20.18769180439039|
|2022|  3| First Half| 6.480485434052824|20.652278174179074|
|2022|  3|Second Half|5.5569449358506535|21.120920554171548|
|2022|  4|Second Half| 5.800344707645977|21.428088376232783|
|2022|  4| First Half| 5.679323077938295|21.515559094583587|
|2022|  5| First Half| 6.249697852127242|21.921570348909114|
|2022|  5|Second Half| 7.906694182348757|22.771948777963715|
|2022|  6| First Half| 6.315157336730177|22.466305309343248|
|2022|  6|Second Half| 6.199832889000861| 22.34284989271931|
+----+---+-----------+-----------------+------------------+
```

Q3 rdd:

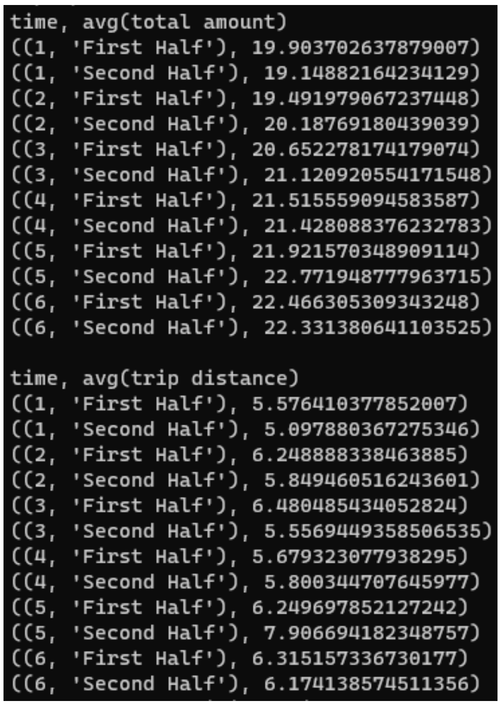

```
time, avg(total amount)
((1, 'First Half'), 19.903702637879007)
((1, 'Second Half'), 19.1488216423412 9)
((2, 'First Half'), 19.491979067237448)
((2, 'Second Half'), 20.18769180439039)
((3, 'First Half'), 20.652278174179074)
((3, 'Second Half'), 21.120920554171548)
((4, 'First Half'), 21.515559094583587)
((4, 'Second Half'), 21.428088376232783)
((5, 'First Half'), 21.921570348909114)
((5, 'Second Half'), 22.771948777963715)
((6, 'First Half'), 22.466305309343248)
((6, 'Second Half'), 22.331380641103525)

time, avg(trip distance)
((1, 'First Half'), 5.576410377852007)
((1, 'Second Half'), 5.097880367275346)
((2, 'First Half'), 6.248888338463885)
((2, 'Second Half'), 5.849460516243601)
((3, 'First Half'), 6.480485434052824)
((3, 'Second Half'), 5.5569449358506535)
((4, 'First Half'), 5.679323077938295)
((4, 'Second Half'), 5.800344707645977)
((5, 'First Half'), 6.249697852127242)
((5, 'Second Half'), 7.906694182348757)
((6, 'First Half'), 6.315157336730177)
((6, 'Second Half'), 6.174138574511356)
```

Q4 sql:

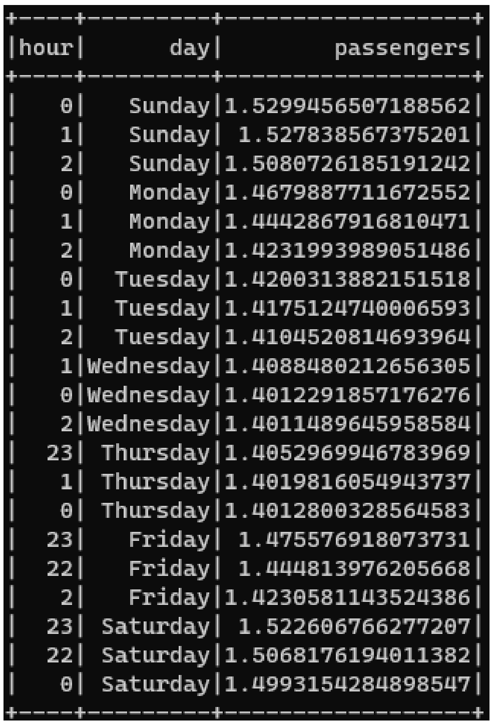

```
+----+---------+------------------+
|hour|      day|        passengers|
+----+---------+------------------+
|   0|   Sunday|1.5299456507188562|
|   1|   Sunday| 1.527838567375201|
|   2|   Sunday|1.5080726185191242|
|   0|   Monday|1.4679887711672552|
|   1|   Monday|1.4442867916810471|
|   2|   Monday|1.4231993989051486|
|   0|  Tuesday|1.4200313882151518|
|   1|  Tuesday|1.4175124740006593|
|   2|  Tuesday|1.4104520814693964|
|   1|Wednesday|1.4088480212656305|
|   0|Wednesday|1.4012291857176276|
|   2|Wednesday|1.4011489645958584|
|  23| Thursday|1.4052969946783969|
|   1| Thursday|1.4019816054943737|
|   0| Thursday|1.4012800328564583|
|  23|   Friday| 1.475576918073731|
|  22|   Friday| 1.444813976205668|
|   2|   Friday|1.4230581143524386|
|  23| Saturday| 1.522606766277207|
|  22| Saturday|1.5068176194011382|
|   0| Saturday|1.4993154284898547|
+----+---------+------------------+
```

Q5 sql:

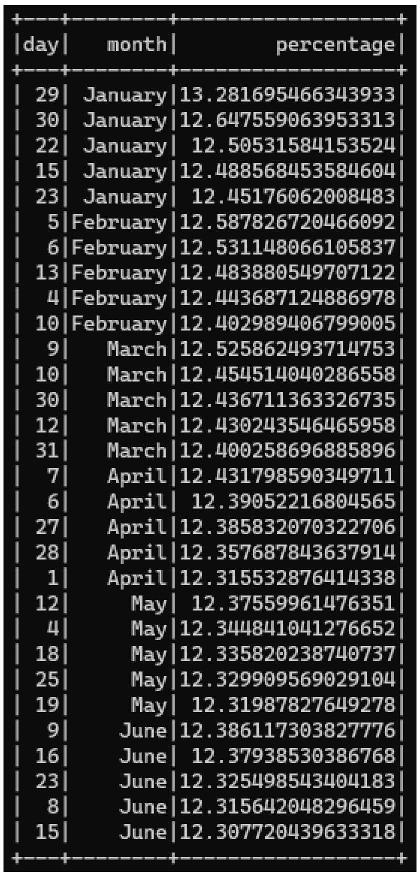

```
+---+--------+------------------+
|day|   month|        percentage|
+---+--------+------------------+
| 29| January|13.281695466343933|
| 30| January|12.647559063953313|
| 22| January| 12.50531584153524|
| 15| January|12.488568453584604|
| 23| January| 12.45176062008483|
|  5|February|12.587826720466092|
|  6|February|12.531148066105837|
| 13|February|12.483880549707122|
|  4|February|12.443687124886978|
| 10|February|12.402989406799005|
|  9|   March|12.525862493714753|
| 10|   March|12.454514040286558|
| 30|   March|12.436711363326735|
| 12|   March|12.430243546465958|
| 31|   March|12.400258696885896|
|  7|   April|12.431798590349711|
|  6|   April| 12.39052216804565|
| 27|   April|12.385832070322706|
| 28|   April|12.357687843637914|
|  1|   April|12.315532876414338|
| 12|     May| 12.37559961476351|
|  4|     May|12.344841041276652|
| 18|     May|12.335820238740737|
| 25|     May|12.329909569029104|
| 19|     May| 12.31987827649278|
|  9|    June|12.386117303827776|
| 16|    June| 12.37938530386768|
| 23|    June|12.325498543404183|
|  8|    June|12.315642048296459|
| 15|    June|12.307720439633318|
+---+--------+------------------+
```

Χρόνοι εκτέλεσης ερωτημάτων

Στο παρακάτω διάγραμμα φαίνονται οι χρόνοι για την εκτέλεση των ερωτημάτων με τους δύο workers και αφού κλείσαμε manually τον έναν worker.

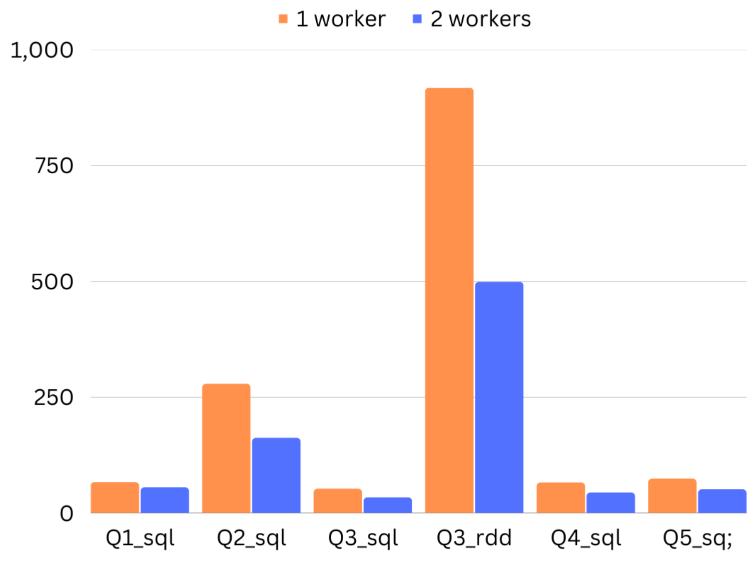

Παρατηρούμε πως σε όλες τις περιπτώσεις οι 2 workers ήταν πιο γρήγοροι από τον 1 worker στην εκτέλεση των ερωτημάτων. Αυτό είναι αναμενόμενο καθώς με τους 2 workers χρησιμοποιούμε διπλάσιο αριθμό cores, σε σχέση με τον 1. Με 2 workers το κάθε query χωρίζεται σε subtasks για τον κάθε worker και εκτελείται παράλληλα, άρα τελικά και πιο γρήγορα. Με τους 2 workers επίσης έχουμε μεγαλύτερο resilience, δηλαδή αν αποτύχει ο ένας worker μπορεί ο άλλος να συνεχίσει και δεν αποτυγχάνει ολόκληρο το query.

Συγκρίνοντας τον χρόνο στο Q3 ανάμεσα στο Spark SQL και στο RDD Api βλέπουμε ότι το RDD κάνει πολύ περισσότερο χρόνο (και στις δύο περιπτώσεις για workers). Αυτό είναι λογικό καθώς το RDD Api δεν διαθέτει κάποιο inbuilt μηχανισμό βελτιστοποίησης, όπως το Spark SQL που χρησιμοποιεί τον catalyst optimizer.

Συγκεκριμένα οι χρόνοι εκτέλεσης των ερωτημάτων σε δευτερόλεπτα φαίνονται πιο αναλυτικά στον πίνακα:

Query	1 worker	2 workers
Q1_sql	66.113	54.938
Q2_sql	278.263	162.119
Q3_sql	52.078	33.520
Q3_rdd	917.271	498.667
Q4_sql	65.386	44.125
Q5_sql	73.646	50.873